

Track1 알고리즘 부문 : K리그-서울시립대 공개 AI 경진대회

Staticronaldo (박태언, 이경욱, 김현우)

January 13, 2026

목차

- 1. 대회개요
- 2. 개발환경
- 3. 피쳐 엔지니어링
- 4. 모델링

- 1. 대회개요

- 추진 배경 및 필요성

- 현대 축구의 패러다임 변화: 단순 선수 기량을 넘어 '공간 창출'과 '유기적 팀 패턴'이 승패의 핵심 요인으로 부상.
 - 기존 분석의 한계: '패스 주체-수신자' 중심의 1차원적 기록에 그쳐, 전술적 의도와 맥락 파악에 어려움 존재.
 - 고차원적 분석 요구: 선수 배치, 압박 강도, 공격 방향 등 복합적 맥락(Context)을 이해하고 최적의 패스 경로를 예측하는 AI 모델 필요.

- 주제

- K리그 경기 데이터 기반 최종 패스 좌표(X, Y) 예측 AI 모델 개발

- 1. 대회개요
 - 평가 지표
 - 유클리드 거리
 - $\text{Score} = \sqrt{(x - \hat{x})^2 + (y - \hat{y})^2}$

- 2. 개발환경
 - Google Colab
 - OS: Linux 6.6.105+
 - RAM: 12.67 GB
 - CPU : Intel(R) Xeon(R) CPU @ 2.00GHz
 - GPU : Nvidia Tesla T4
 - CUDA Version: 12.6
 - Total VRAM: 14.74 GB

- 3. 피쳐 엔지니어링
 - 시계열 및 동적 특성 반영
 - 시간/행동 간격 산출: 이전 이벤트와의 시간 차이(time_diff) 및 액션 ID 공백(action_id_gap)을 계산하여 누락된 동작의 밀도 추정.
 - 이동 특성 수치화: 이전 좌표 대비 이동 거리(dist_from_prev) 및 속도 개념의 파생 변수 생성.

- 3. 피쳐 엔지니어링

- 공간 및 기하학적 분석

- 골대 기준 좌표 변환: 골대와의 거리(dist_to_goal) 및 각도(angle_to_goal)를 계산하여 공격 상황의 위협도 반영.
 - 방향성 일관성(direction consistency): 선수의 이전 이동 방향과 골대 방향 사이의 코사인 유사도를 산출하여 전진/후퇴 경향성 파악.
 - 이동 각도 변화량: 이전 움직임 벡터와 현재 움직임 벡터 간의 각도 차이(angle_diff)를 통해 급격한 방향 전환 여부 학습.

- 3. 피쳐 엔지니어링
 - 경기 맥락 및 전술적 구역 정의
 - 전술 구역 세분화: 경기장을 3x3 그리드로 나누어 9개의 전술적 구역 ID(zone_id) 부여.
 - 특수 구역 플래그: 득점 확률이 높은 페널티 박스 진입 여부(in_box)를 이진 변수(0/1)로 생성.
 - 매치 정보 결합: 홈/어웨이 여부 및 상대 팀 정보를 병합하여 경기장 환경(venue)에 따른 변수 추가.


- 4. 모델링
 - 모델 선정 및 학습 목표
 - Base Model: TabPFN 2.5 (Tabular Prior-Data Fitted Network 2.5) 활용.
 - 정형 데이터(Tabular Data) 처리에 특화된 Transformer 기반 모델.
 - `output_type="median"` 설정을 통해 모델 내부적으로 이상치에 강한 예측값(중앙값)을 도출하도록 설정.
 - Target Definition: 절대 좌표(x, y)가 아닌 변화량($\Delta x, \Delta y$)을 예측하여 학습 안정성 확보.

- 4. 모델링
 - 파인튜닝
 - Pre-trained TabPFN 2.5 가중치를 K-리그 데이터셋에 맞춰 조정.
 - 학습 설정 : Optimizer: AdamW (Learning Rate: 0.0001)
 - Loss Function: L1Loss
 - Epochs: 20 Epoch
 - Input Shape: (Seq, Batch, Feat) 형태로 텐서 차원 재구성하여 학습 진행.

- 4. 모델링
 - 검증 및 앙상블
 - 5-Fold Cross Validation: 데이터를 5개 폴드로 나누어 교차 검증 수행.
 - Average Ensemble: 5개 Fold 모델이 각각 예측한 결과를 산술 평균하여 최종 예측값 도출.

- 4. 모델링
 - 후처리
 - 좌표 보정(Clipping): 경기장 규격($0 \leq x \leq 105, 0 \leq y \leq 68$) 을 벗어난 예측값을 경계값으로 보정하여 물리적 정합성 확보.

- 4. 모델링



- 번외(전처리의 역설)
 - 기존 통념과의 괴리
 - 일반적인 딥러닝 방법론(이상치 제거 등) 적용 시, 오히려 모델 성능(MAE)이 하락하는 현상 관측
 - 인위적인 데이터 분포 변환이 원본 데이터가 가진 미세한 정보를 손실시키는 것으로 판단

- 번외(전처리의 역설)
 - 모델 특성에 따른 원인 분석
 - TabPFN의 특성: 방대한 양의 사전 데이터를 학습하여, 정형 데이터의 다양한 분포 패턴을 이미 내재화하고 있는 모델
 - 이상치에 대한 제거 또는 분포 변환의 전처리 방법이 오히려 모델의 추론을 방해하는 것으로 보임.
 - 최종 전략
 - Feature Generation 집중: 데이터의 형태를 바꾸는 것보다, 피쳐 엔지니어링의 추가가 성능 향상의 핵심임을 입증.

감사합니다